

Análisis Visual de Problemas de Granularidad y Ambigüedad en el Agrupamiento de Intenciones con LLMs: Caso CLINC150

Cecilia del Pilar Vilca Alvites
Escuela Profesional Ciencia de la Computación
Universidad Nacional de San Agustín
Arequipa, Perú
cvilcaal@unsa.edu.pe

I. INTRODUCCIÓN

En la actualidad, la creciente cantidad de información en forma de texto representa un reto importante para el procesamiento de lenguaje natural (NLP). Esto es especialmente cierto en tareas no supervisadas, como el agrupamiento automático de frases según la intención del usuario, que es común en sistemas como asistentes virtuales o chatbots. Organizar y entender grandes volúmenes de texto sin etiquetas previas requiere métodos efectivos y comprensibles.

Los Modelos de Lenguaje de Gran Escala (LLMs) han revolucionado la manera en que representamos el significado del texto, generando embeddings que capturan el contexto y la semántica de las frases [2]. Estas representaciones permiten agrupar textos similares con mayor precisión. Sin embargo, los métodos basados en LLMs suelen funcionar como “cajas negras”, lo que dificulta entender por qué ciertos textos se agrupan de una forma determinada y limita la interpretación de los resultados [1].

Un desafío importante surge de la alta granularidad presente en muchos conjuntos de datos de intenciones. Estos datos suelen contener numerosas categorías que, aunque diferentes, son semánticamente muy próximas [3]. Los embeddings generados por LLMs pueden agrupar frases con significados similares, pero a menudo no logran separar claramente intenciones que difieren de forma sutil, provocando solapamientos entre las clases. Por otro lado, la ambigüedad inherente al lenguaje natural añade complejidad, ya que frases idénticas o muy parecidas pueden estar asociadas a intenciones distintas, reflejando la riqueza y variabilidad del lenguaje humano [5]. Esta ambigüedad representa un reto difícil de resolver con métodos automáticos, pues requiere un análisis contextual profundo.

La dificultad para diagnosticar estos problemas se agrava debido a la falta de herramientas visuales interactivas que permitan a los analistas explorar y comprender los agrupamientos. Los sistemas existentes rara vez combinan visualización analítica con retroalimentación humana, lo que limita la detección de errores, la identificación de consultas anómalas y el ajuste manual de clústeres [1], [4]. Contar con recursos

que faciliten esta interpretación es crucial para mejorar la calidad de los agrupamientos.

Ante estos retos, el presente proyecto propone el desarrollo de una herramienta visual interactiva basada en D3.js, que aproveche los embeddings generados por LLMs para analizar el dataset CLINC150, compuesto por conversaciones de usuarios. El objetivo es facilitar la exploración y diagnóstico de la estructura de los clústeres, identificar patrones problemáticos como la granularidad excesiva y la ambigüedad, y permitir la mejora iterativa de los resultados. Para ello, la herramienta integrará técnicas de análisis temático, incluirá métricas internas para evaluar la calidad de los grupos y ofrecerá una interfaz dinámica que permita al usuario modificar y refinar la cantidad y composición de los clústeres.

De esta manera, el proyecto busca aportar una solución que combine la potencia de los modelos avanzados de lenguaje con la capacidad humana para interpretar y mejorar los agrupamientos, contribuyendo a superar los desafíos inherentes al procesamiento no supervisado de intenciones en lenguaje natural.

REFERENCES

- [1] R. Peng, Y. Dong, G. Li, D. Tian, and G. Shan, “TextLens: Large language models-powered visual analytics enhancing text clustering,” *Journal of Intelligent & Fuzzy Systems*, DOI: 10.1007/s12650-025-01043-y, Feb. 2025.
- [2] A. Petukhova, J. Carvalho, and N. Fachada, “Text Clustering with Large Language Model Embeddings,” *International Journal of Cognitive Computing in Engineering*, vol. 6, pp. 100–108, Dec. 2025.
- [3] N. Arias, P. Singh, and A. B. Imbert, “Visual Analytics for Fine-grained Text Classification Models and Datasets,” *arXiv preprint arXiv:2405.02980*, 2024.
- [4] L. K. Miller and C. P. Alexander, “Human-interpretable clustering of short text using large language models,” *Royal Society Open Science*, vol. 12, no. 2, pp. 241088, 2025.
- [5] S. Hamada, “Processing of Semantic Ambiguity Based on Words Ontology,” *Journal of Computer Science*, vol. 16, no. 1, pp. 1–9, 2020.